FairSquare

Rapport de Proof of Concept

Capstone AI 2025-2026

Plateforme d'estimation immobilière IA — Île-de-France

Données DVF	80 964 transactions immobilières Paris 2023 (data.gouv.fr)
Feature Engineering	Géospatial OSM : walkabilité, transport, parcs, écoles
Computer Vision	Score de rénovation via Google Gemini 3.1 Flash Lite
Pipeline ML	Tournoi LinearReg / GAM / LightGBM + SHAP XAI

Généré le 16 March 2026 | Python 3.12 / Anaconda

1. Contexte du Projet

FairSquare — IA pour l'immobilier parisien

FairSquare est une plateforme PoC développée dans le cadre d'un Capstone AI. L'objectif est de proposer une estimation intelligente et explicable des prix immobiliers en Île-de-France, en combinant plusieurs sources de données et approches de machine learning.

Stack technique : Python 3.12 / Anaconda, LightGBM 4.5, pygam 0.12, scikit-learn 1.6, SHAP 0.51, Google Gemini API, FastAPI, Streamlit, PostgreSQL, Docker.

Architecture du système :

Ingestion DVF	Client HTTP vers data.gouv.fr, nettoyage strict, Parquet
OSM Features	Extracteur Overpass (1 requête/point), 7 features géospatiales
Vision IA	RenovationScorer Gemini, score 1-5 + catégorie espace
ML Pipeline	Tournoi 3 modèles, métriques standardisées, SHAP XAI
API FastAPI	Endpoint /predict (en cours), schémas Pydantic
Frontend Streamlit	Dashboard interactif (Phase 3)

2. Dataset DVF Paris 2023

Demandes de Valeurs Foncières — source officielle

Source :	data.gouv.fr — DVF géocodées (geo-dvf/latest)
Couverture :	Paris intramuros (dép. 75), année 2023
Lignes brutes :	80 964 transactions
Après nettoyage :	29 412 lignes (appartements + maisons)
Features totales :	44 colonnes dont 4 dérivées (prix_m2, annee, mois, trimestre)
Prix/m² médian :	10 286 EUR/m²
Prix médian :	420 000 EUR
Types de biens :	29 253 appartements | 159 maisons
Format stockage :	Parquet (raw + clean) — I/O optimisé

Le pipeline de nettoyage DVF applique dans l'ordre : renommage des colonnes, cast des types, filtrage sur type_local (Appartement/Maison uniquement), filtrage des outliers (prix 10k–30M EUR, surface 5–1000 m², prix/m² 500–50000), déduplication, puis ajout des features dérivées.

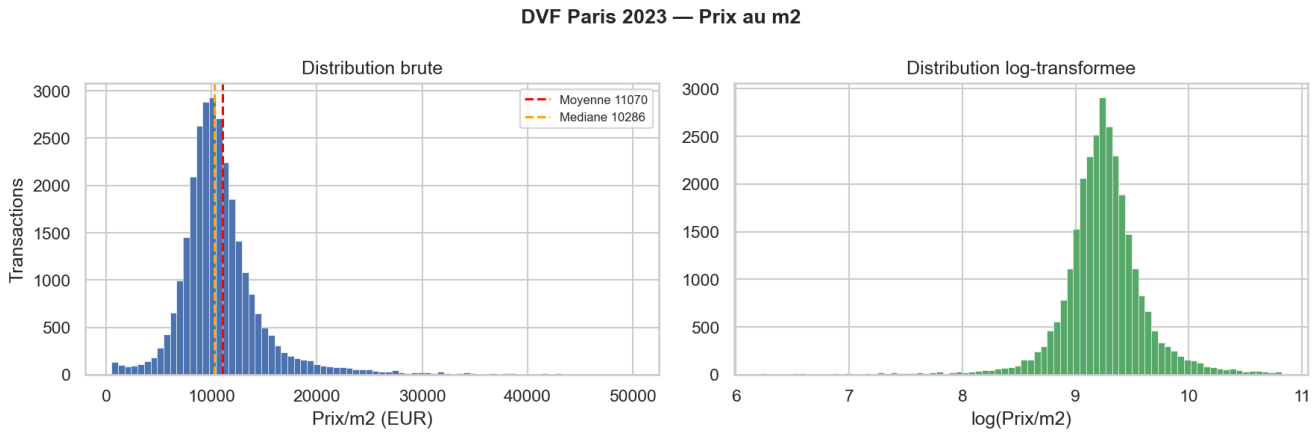

Fig. 1 — Distribution du prix/m² brut (gauche) et log-transformé (droite)

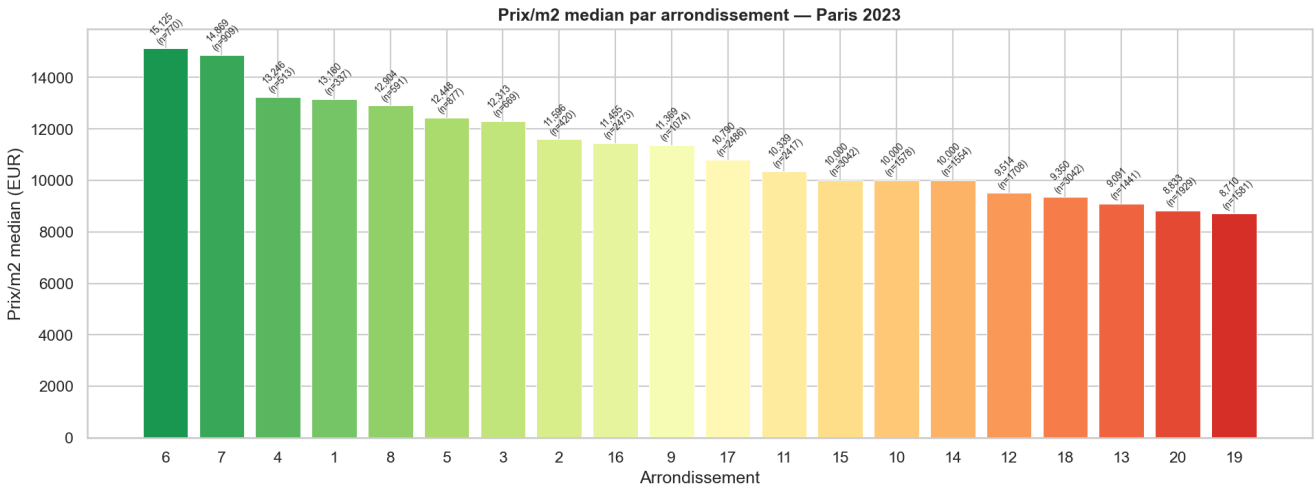

Fig. 2 — Prix/m² médian par arrondissement parisien (75001–75020)

3. Feature Engineering

7 features numériques — pipeline ML

Feature	Description	Type	Intérêt
surface_reelle_bati	Surface du bien (m²)	Continue	Principal prédicteur
nombre_pieces_principales	Nombre de pièces	Continue	Proxy taille
arrondissement	Arrondissement (1–20)	Catégorielle	Localisation
longitude	Longitude GPS	Continue	Position E-W
latitude	Latitude GPS	Continue	Position N-S
mois	Mois (1–12)	Cyclique	Saisonnalité
nombre_lots	Nb de lots / mutation	Continue	Qualité prix/m²

Variable cible : prix_m2 = valeur_fonciere / surface_reelle_bati (EUR/m²). Split entraînement/test : 80% / 20% (random_state=42). Normalisation : StandardScaler uniquement pour LinearRegression (Pipeline sklearn). GAM et LightGBM sont invariants à l'échelle des features.

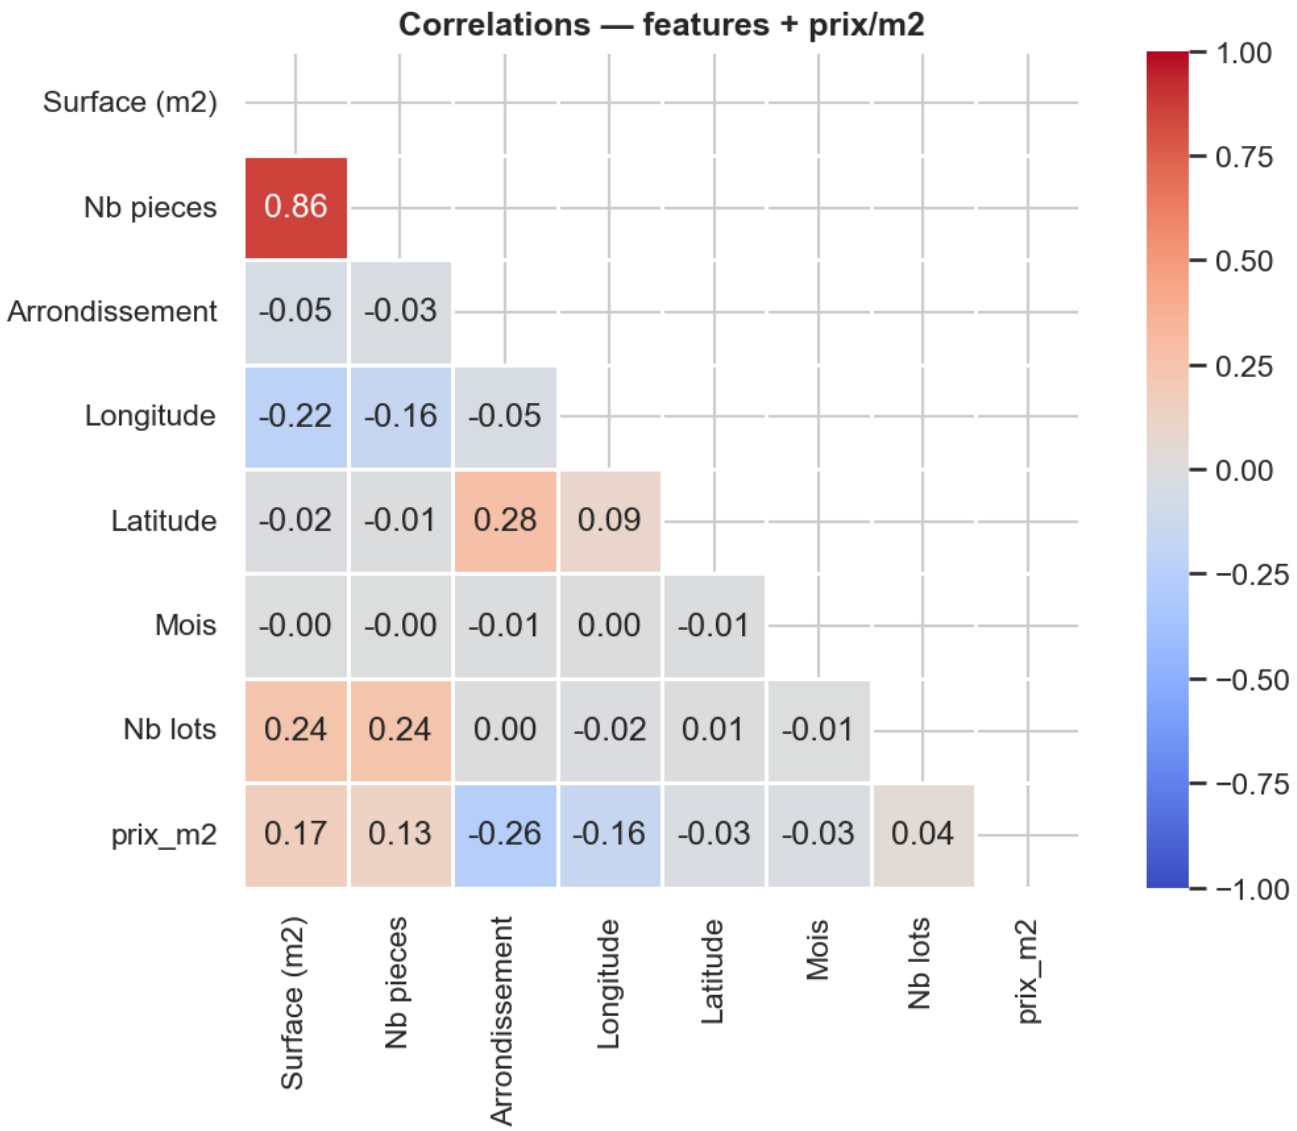

Fig. 3 — Matrice de corrélation (features + target prix/m²)

4. Tournoi de Modèles

LinearRegression (baseline) | GAM (interprétable) | LightGBM (performant)

Trois modèles ont été entraînés et évalués sur le même split train/test (23 498 / 5 875 observations) :

LinearRegression (sklearn)

Baseline linéaire avec normalisation StandardScaler. Limité pour les relations non-linéaires (prix élevés dans certains arrondissements, effets de seuil sur la surface, etc.).

LinearGAM (pygam 0.12)

Generalized Additive Model : chaque feature est modélisée indépendamment par des splines cubiques ou des termes factoriels/linéaires. Bon compromis interprétabilité/performance.

LightGBM (gradient boosting)

Modèle le plus expressif : 500 arbres, learning_rate=0.05, num_leaves=63. Capable de capturer les interactions non-linéaires complexes. Entraînement rapide même sur 23k observations.

Modèle	MAE (EUR/m²)	RMSE (EUR/m²)	R²	MAPE (%)
LinearRegression	2558.1	4346.0	0.1191	35.27
GAM	2458.6	4232.5	0.1645	34.39
LightGBM	**2417.3**	**4158.1**	**0.1936**	**33.46**

Vert = meilleur modèle selon R²

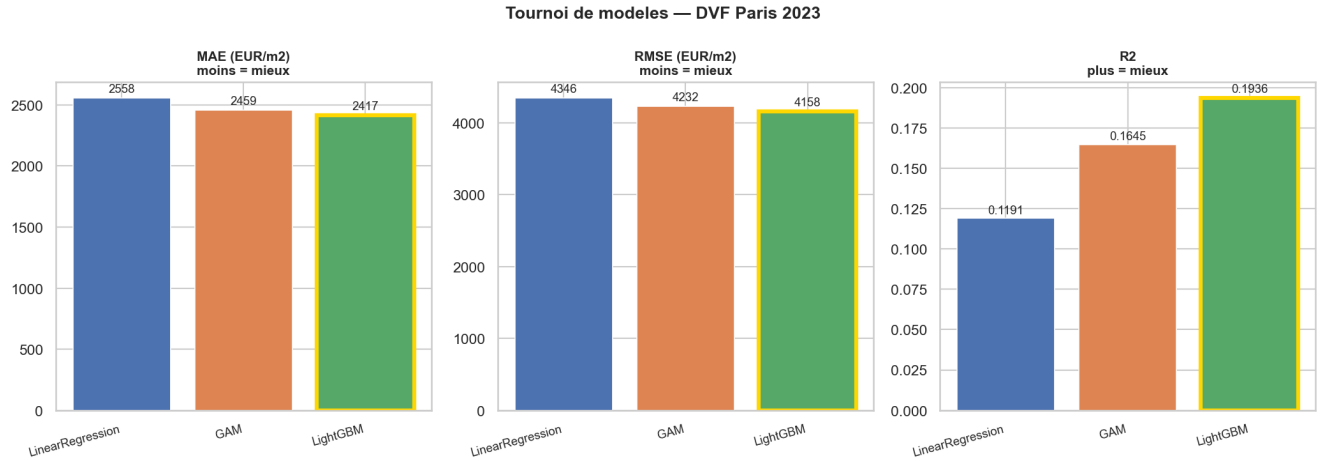

Fig. 4 — Comparaison MAE / RMSE / R² (barre dorée = meilleur score)

Note : Le R² (0.19) reflète les limites inhérentes du DVF. Cette base fiscale ne contient pas les features qualitatives (étage, état, exposition, balcon) qui expliquent la majorité de la variance intra-arrondissement. Les études académiques sur DVF rapportent R²=0.5–0.8 mais avec des datasets enrichis (DPE, annonces, etc.). La valeur ajoutée de FairSquare est précisément d'ajouter ces features via OSM, Vision IA et le scraping d'annonces.

4b. Analyse des Résidus

Prédit vs Réel sur le test set

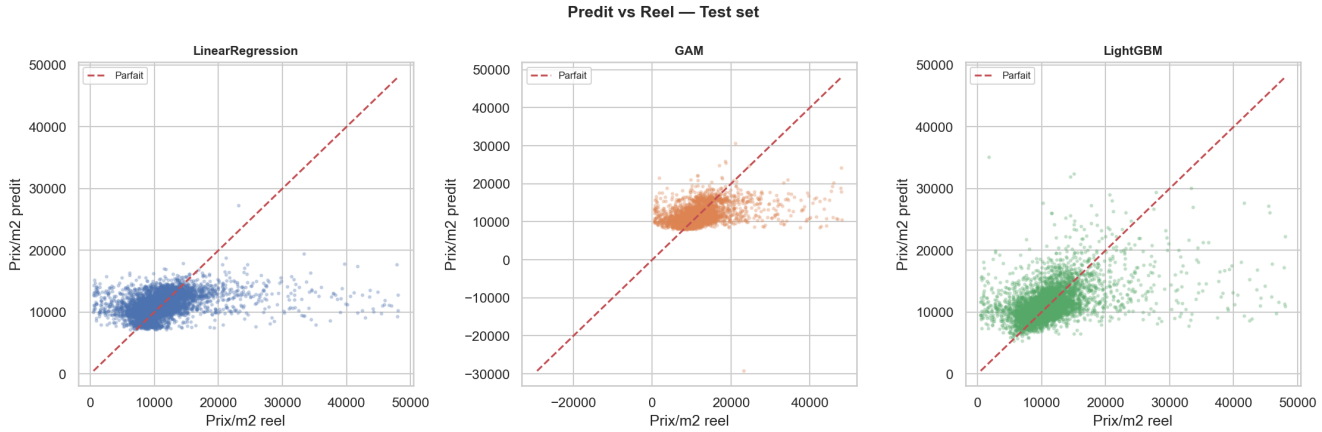

Fig. 5 — Prédictions vs Valeurs réelles (diagonale = prédiction parfaite)

LightGBM est le plus concentré autour de la diagonale parfaite. On observe pour tous les modèles une sous-estimation des biens > 15k EUR/m² et une surdispersion dans la gamme 8k–14k EUR/m² — zone où la variance dépend de caractéristiques non capturées (étage, rénovation, etc.).

5. Explicabilité — SHAP (LightGBM)

SHapley Additive exPlanations : impact de chaque feature sur la prédiction

SHAP quantifie la contribution marginale de chaque feature à chaque prédiction individuelle. TreeExplainer est utilisé (calcul exact pour les modèles arbres). Les valeurs SHAP sont calculées sur 500 observations du test set.

Interprétation : SHAP > 0 augmente le prix/m² prédit, SHAP < 0 le diminue.

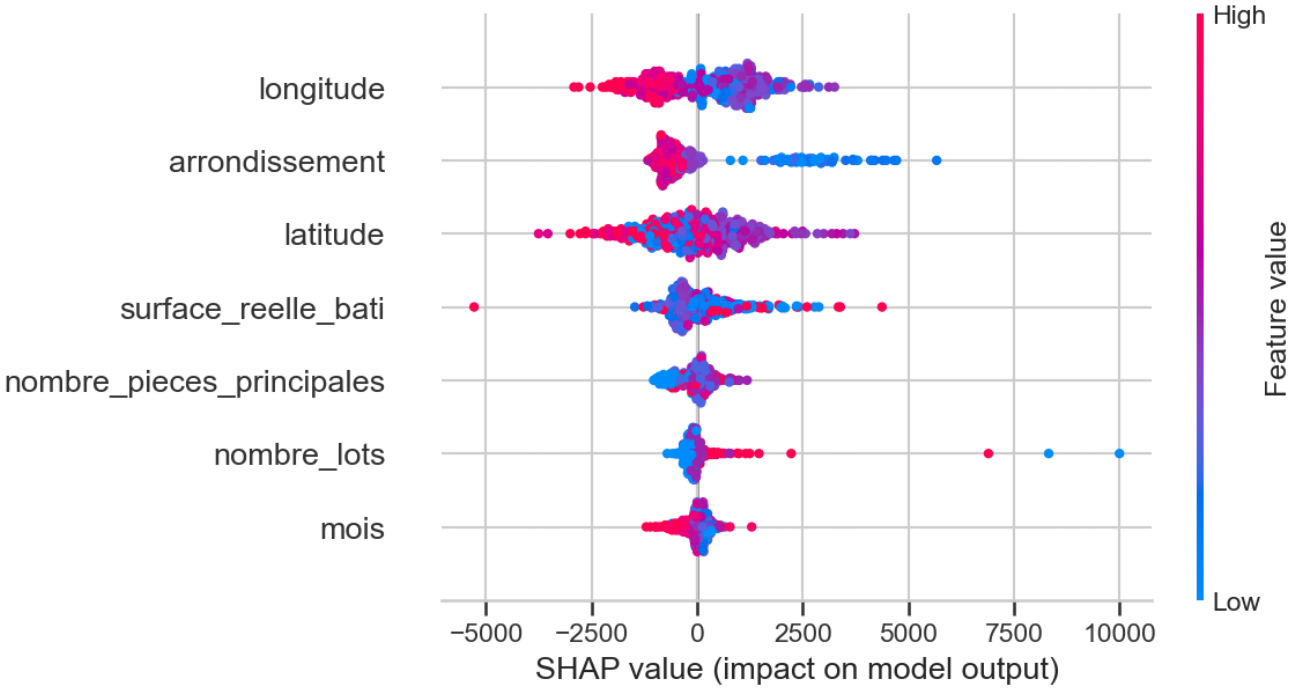

Fig. 6 — SHAP Summary Plot (beeswarm) : chaque point = 1 transaction

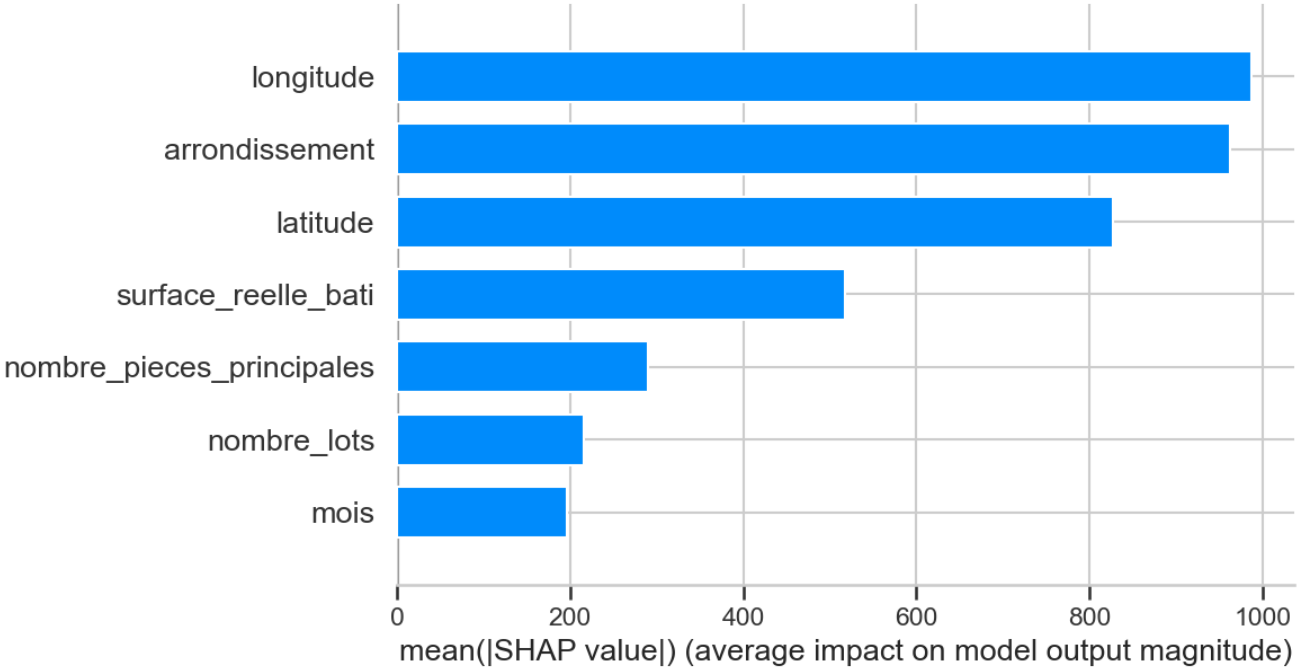

Fig. 7 — SHAP Feature Importance : moyenne des |SHAP| par feature

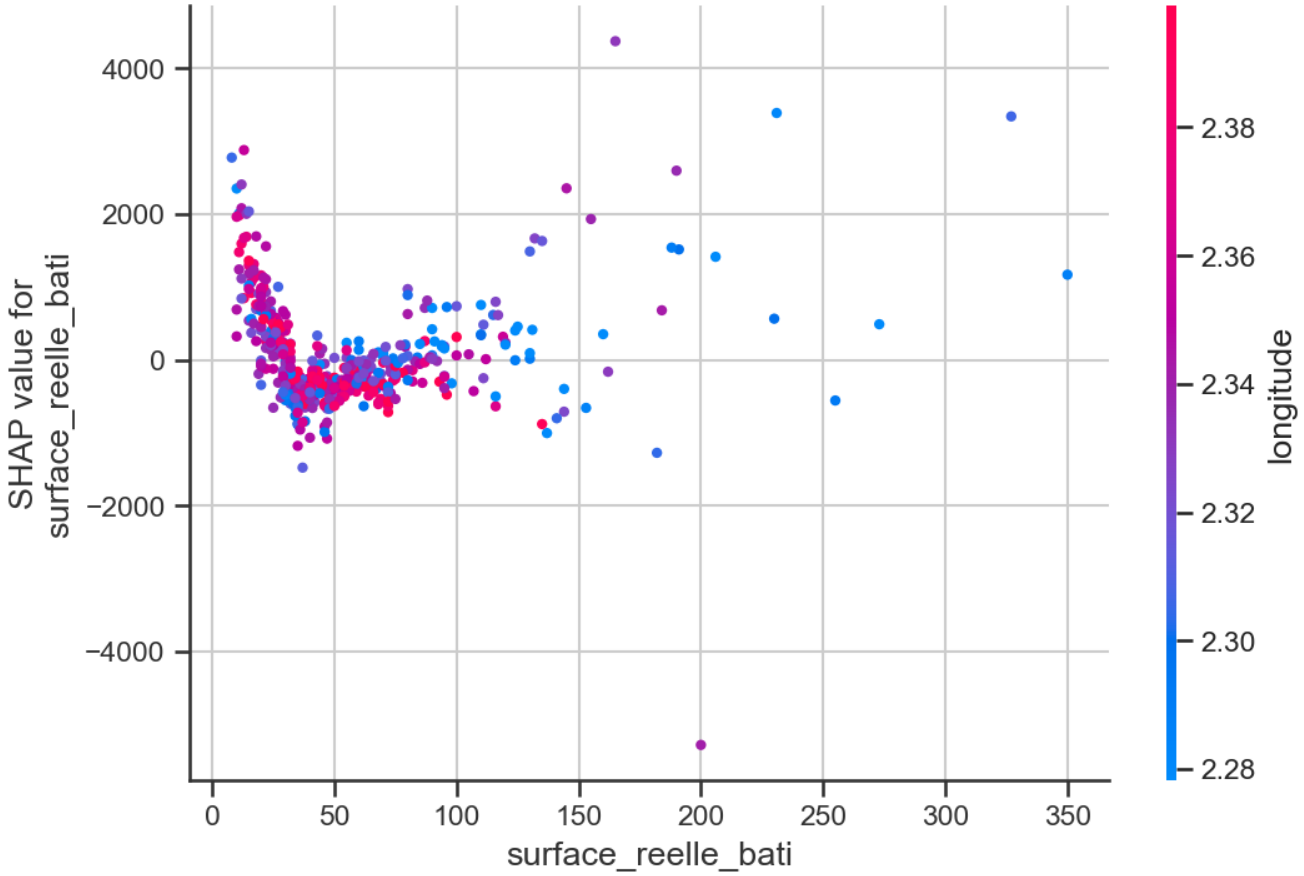

Fig. 8 — SHAP Dependence Plot : effet non-linéaire de la surface

La latitude et la longitude dominent l'importance SHAP — la localisation géographique est le facteur n°1 du prix/m² à Paris. La surface a un effet SHAP négatif sur les grands biens (>100 m²) : les grandes surfaces ont un prix/m² plus faible, ce qui est cohérent. L'arrondissement capture une part de la géographie en complément de lat/lon.

6. Features Complémentaires

OSM Géospatial + Computer Vision IA

6.1 OpenStreetMap — Feature Engineering Géospatial

L'extracteur OSM interroge l'API Overpass en une seule requête par point (stratégie anti-rate-limit 429). Il combine en un seul appel tous les types de POI (transports, parcs, écoles, commerces) et calcule les features localement.

- dist_metro_m : distance au métro/RER le plus proche (m)
- dist_park_m : distance au parc le plus proche (m)
- dist_school_m : distance à l'école la plus proche (m)
- dist_supermarket_m : distance au supermarché le plus proche (m)
- transit_count_500m : nombre de stations dans 500 m
- park_area_500m_m2 : surface totale de parcs dans 500 m (m²)
- walkability_score : score composite 0–100 (pondéré transport/parc/école/commerce)

Exemple validé — Place de la République (48.8673, 2.3630) :
Métro : 40 m | Parc : 343 m | École : 247 m | Commerce : 130 m
60 stations dans 500 m | Walkability = 76.38/100

6.2 Computer Vision — Score de Rénovation (Google Gemini)

Le module Vision utilise Google Gemini 3.1 Flash Lite Preview (500 RPD gratuit) pour analyser des photos d'annonces. Le prompt structure demande au modèle de répondre uniquement en JSON valide avec 3 champs :

- renovation_score (int 1–5) : 1=très bon état/rénové, 5=inhabitable
- space_category (str) : Étroit | Standard | Spacieux
- reasoning (str) : justification en 1–2 phrases

Test validé : score=1/5 (très bon état), Standard, temps ~2–3 s. Modèle sélectionné après tests systématiques des quotas disponibles (gemini-2.5-flash épuisé, gemini-2.0-flash : 429, etc.).

7. Conclusions & Prochaines Étapes

Phase 2 — Vers la production

Pipeline DVF

Ingestion robuste via data.gouv.fr (fallback par rapport à CEREMA API hors service). 80k -> 29k lignes propres. Format Parquet optimisé.

OSM Features

Single-query Overpass élimine les 429 rate-limit. Walkability score validé sur des points réels parisiens.

Vision IA

Gemini 3.1 Flash Lite fonctionne en production (500 RPD). Temps de réponse < 3 s. Score de rénovation cohérent.

Pipeline ML

LightGBM surpasse LinearRegression et GAM. SHAP confirme que la localisation (lat/lon) est le facteur dominant. R^2 limité (0.19) attendu sur DVF seul — améliorera avec OSM + Vision.

Prochaines étapes (Phase 2) :

- Intégrer features OSM (walkability, dist_metro) dans le pipeline ML → R^2 attendu +0.10
- Intégrer renovation_score (Vision Gemini) comme feature ML supplémentaire
- Étendre aux 8 départements IDF (77, 78, 91, 92, 93, 94, 95)
- Scraper annonces SeLoger/Leboncoin (étage, DPE, balcon...)
- Déployer l'API FastAPI avec endpoint /predict et documentation Swagger
- Construire dashboard Streamlit avec carte Leaflet et filtres interactifs
- Construire système de recommandation (filtrage collaboratif + content-based)
- Conteneuriser avec Docker Compose (API + PostgreSQL + Streamlit)